

INFORME TÉCNICO · CÓMO ESPECIALIZAR EL CHAT PARA TRUCCO

Pedido al CTO · armar argumento técnico para que Trucco se maraville con la herramienta

Fecha	2026-05-05 (martes · misma jornada que cierre Sprint Sovereign V1)
De	Programador (Claude · operando con MCP filesystem sobre el repo)
Para	CTO externo · vía Juan (lead Vision Patagonia)
Asunto	Pedido de recomendación técnica · cómo especializar el chat NEXUS en Contabilidad para impactar a Gustavo Trucco (auditor académico · eminencia en la materia)
Origen	Lead reportó que en la conversación previa con Trucco lo que más le impactó del Portal fue el chat. Con P3 deployado en nexus-contabilidad.vercel.app la pieza está lista para el contacto · ahora hay que asegurar que cuando Trucco pruebe el chat se vaya con efecto wow.

Sumario ejecutivo

El deploy P3 quedó listo en <https://nexus-contabilidad.vercel.app>. KB filtrada a 173 entries de Contabilidad. Banner identificatorio en el top. Title del browser actualizado. Lo que queda como riesgo crítico: cuando Trucco pruebe el chat, el comportamiento default actual (Llama 3.2 + system prompt académico genérico + matching threshold estándar) puede que no le impacte si él pregunta cosas técnicas profundas de Contabilidad. Necesitamos elevarlo a nivel auditor académico.

Pido recomendación específica del CTO sobre 5 ejes de especialización. Mi rol como programador es ejecutivo · no decido entre Mistral y Llama, entre threshold ajustado y refuse strict, entre ingesta nueva o no. Te paso las hipótesis con trade-offs y vos arbitrás.

Qué hay ya deployado y verificado

Item	Detalle	Hash / dato
URL fija	https://nexus-contabilidad.vercel.app · alias estable del proyecto Vercel nexus-contabilidad	—
Deploy específico	nexus-contabilidad-rejqjtcka-visionpatagonia-bits-projects.vercel.app · 9s build	rejqjtcka
Banner identificatorio	Barra naranja Anubis arriba con position:fixed (no rompe layout flex del Portal). Texto: 'Versión Contabilidad · Actualizado tras feedback de auditor académico · Citas verificadas literalmente desde RT 16, RT 54 NUA e IASB Marco Conceptual'	—
KB filtrada	173 entries de materia=Contabilidad (de las 271 totales del Portal académico). Metadata filter_applied=solo_contabilidad_trucco persistido en el JSON	b591b7526ceb03e1
Title browser	'NEXUS Contabilidad · Versión Auditor Académico'	—
Build script reusable	scripts/build_trucco.py corregido · próximas iteraciones se hacen con 1 comando + vercel deploy --prod	—

Limitaciones del approach actual (lo que NO cambió respecto al Portal académico)

Por honestidad técnica antes de pedir recomendación: el corte actual es solo a nivel KB. Esto deja 4 cosas sin filtrar que conviene tener presentes:

Item	Detalle	Hash / dato
Sidebar UI	Sigue mostrando las 4 materias del Portal (Propedéutica, Contabilidad, Administración, Sociales). Si Trucco hace click en otra materia, accede al contenido pleno	no filtrado
Modo Pánico	Dice '4 materias · 25 minutos'. Genera quiz mezclado con preguntas de las 4	no filtrado
Materiales/recursos JSON	materiales.json, glossary.json, noticias.json sin filtro · siguen los del Portal completo	no filtrado
Chat (este es el crítico)	Default Llama 3.2 vía proxy local de Juan + tunnel Cloudflare. Si Juan no tiene proxy y tunnel arriba cuando Trucco entra, el chat muestra 'Sin conexión al asistente'. Si tiene todo prendido, responde con system prompt académico genérico, sin especialización Contabilidad explícita	ver hipótesis abajo

Por qué el foco va al chat

El lead reportó que en la conversación previa con Trucco, lo que más le interesó del Portal fue el chat NEXUS. Trucco es eminencia en Contabilidad · auditor académico que dedica su carrera a hacer revisión técnica precisa de documentos contables. Para él, un chat genérico que responda razonablemente bien NO va a ser memorable. Para impactarlo necesitamos que el chat:

- Responda con citas literales de las normas que ÉL conoce (RT 16, RT 54 NUA, IASB Marco Conceptual).
- Refuse honestamente cuando no sabe en vez de inventar (eminencia en la materia detecta una alucinación al primer intento · si pasa, perdemos credibilidad inmediatamente).
- Cite la fuente al pie con número de página o sección · Trucco va a verificar la cita.
- Use vocabulario técnico-contable propio del campo argentino (no traducción de inglés genérico).
- Tenga el comportamiento que un auditor esperaría de un asistente de su mismo nivel · breve, preciso, sin paja pedagógica.

Hipótesis del programador · 5 ejes de especialización

Te paso las opciones que veo desde el código (lectura del repo · MCP filesystem) con trade-offs honestos. No tengo forma de elegir entre estas sin tu criterio.

#	Hipótesis	Por qué + cómo aplicar	Costo
1	Switchear a Mistral 7B Q4_K_M para queries de Contabilidad	El proxy actualmente default Llama 3.2 (línea 34 server.js). Mistral 7B Q4_K_M ya está disponible vía Ollama y el patch v19.30.6 acepta override de modelo desde body (requestedModel). Para Contabilidad puede ayudar porque Mistral fue el que generó las 138 entries originales del KB · 'habla' el vocabulario contable que ya está en la base. Hipótesis: matching CKG > KB > Mistral (vs Llama) tendría más coherencia léxica con lo que Trucco ya leería en el banner. Implementación: cambiar default model en frontend cuando ?ui=contabilidad o cuando dominio = nexus-contabilidad.vercel.app	1-2h

#	Hipótesis	Por qué + cómo aplicar	Costo
2	System prompt 'modo auditor académico' específico para Trucco	El proxy ya tiene system prompts adaptativos por materia (directo / pedagógico / socrático según docs). Crear uno nuevo 'auditor_academico' con instrucciones específicas: (a) responder en máximo 3 párrafos, (b) citar siempre fuente y página, (c) refuse explícito si no hay match en KB (no 'inferir' desde contexto), (d) vocabulario técnico-contable argentino sin traducciones genéricas, (e) si el usuario pregunta algo fuera de Contabilidad, derivar al portal académico completo en vez de inventar	2-3h
3	Ingestar el método de Trucco al CKG (si conseguimos sus papers/notas)	Hoy las 32 entries CKG-backed son del Marco Conceptual IASB + RT 16 + RT 54 NUA. Si Trucco compartiera 1-2 papers suyos o sus notas pedagógicas, podríamos ingestarlas con framework_scope=METHOD_TRUCCO y prioridad sobre las regulatory. El chat respondería 'según Trucco, X' citándolo a él literal. Esto es lo que más wow generaría · pero requiere que Trucco coopere entregando material suyo y aceptando que se ingeste	5-8h + cooperación de Trucco
4	Refuse threshold más agresivo en modo Trucco	Actualmente el matcher Jaccard tiene threshold típico ~0.5 para considerar KB hit. Para Trucco subirlo a 0.7-0.8 · si hay duda, refuse honesto antes que respuesta tibia. Mejor 5 refuses claros que 1 alucinación. Implementación: parámetro environmental en proxy o header X-Strict-Mode=true	30 min
5	Telemetría dedicada del chat de Trucco	Capturar JSONL append-only de cada interacción de Trucco (timestamp, query, match origin (CKG/KB/LLM/refuse), response, latencia, hit/miss). Para que el lead pueda revisar después de la reunión qué preguntó, qué respondimos, qué le gustó (puede pedirle a Trucco que dé thumbs up/down con un botón en el chat). Información clave para iterar la versión 2	2-3h

Pedidos concretos al CTO

1 · Recomendación de combinación

De las 5 hipótesis arriba, ¿cuáles aplico antes del primer encuentro con Trucco? Mi sugerencia operativa (sujeta a tu criterio): hipótesis 2 (system prompt auditor) + hipótesis 4 (refuse threshold) son las dos baratas y de alto impacto · 2-3.5h totales. Hipótesis 1 (Mistral switch) si tu lectura del modelo coincide con la mía. Hipótesis 3 (ingesta método Trucco) la dejaría para post-reunión cuando ya tengamos su feedback. Hipótesis 5 (telemetría) la haría sí o sí en paralelo · sin esto no podemos iterar después.

2 · Disponibilidad del proxy + tunnel cuando Trucco pruebe

El chat depende del proxy local de Juan + tunnel Cloudflare. Si Trucco entra cuando Juan tiene la PC apagada o el proxy caído, el chat va a tirar 'Sin conexión'. ¿Coordinamos ventana fija con Trucco (vos avisás Juan: 'el martes 14h estará disponible') o asumimos que esto es un riesgo aceptable de un piloto y ya?

3 · Si recomendás ingesta del método Trucco · cómo pedimos el material

Si la hipótesis 3 te parece prioridad, necesitamos que Trucco mande sus papers o notas. ¿Esa pregunta la hace el lead en la primera reunión o el Director de Equipo arma un mensaje específico para pedirlo? Es un pedido delicado · entrega de material académico personal.

4 · Branding del chat para Trucco

El chat actualmente se llama 'NEXUS Co-worker · llama3.2 · GPU local'. Para Trucco quizás cambiarlo a 'NEXUS Auditor · contabilidad académica' con la indicación del modelo según lo que decidas en el punto 1. ¿Vale el rebrand del chat para diferenciar la versión auditor de la versión alumnos?

Cierre

La pieza P3 está deployada y verificada visualmente. El próximo movimiento de impacto es asegurar que el chat dé efecto wow cuando Trucco lo pruebe · porque ese es el punto que él valoró en la conversación previa según reporte del lead.

Quedo a disposición para ejecutar las hipótesis que recomiendes en el orden que arbites. Si para alguna necesitás detalle adicional del código (ej. ver el system prompt actual del proxy, o el matcher Jaccard exacto), te lo paso en minutos vía MCP filesystem.